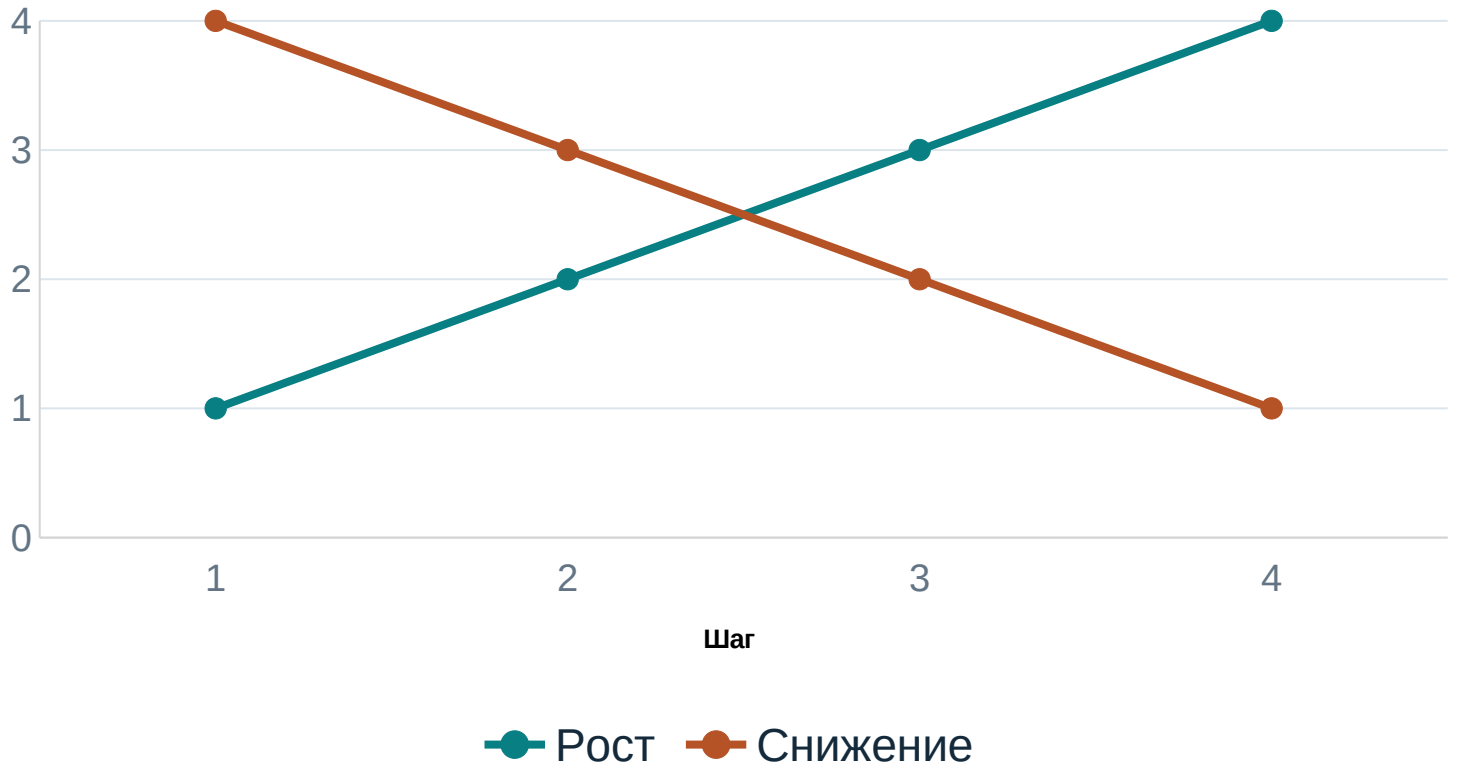
Рекуррентные нейронные сети

Как сеть использует порядок
и переносит контекст

RNN

Основы машинного обучения
Команда 24

Одинаковые числа, разный порядок



2,5

среднее
в обоих случаях

Среднее теряет порядок. Для ответа нужна последовательность.

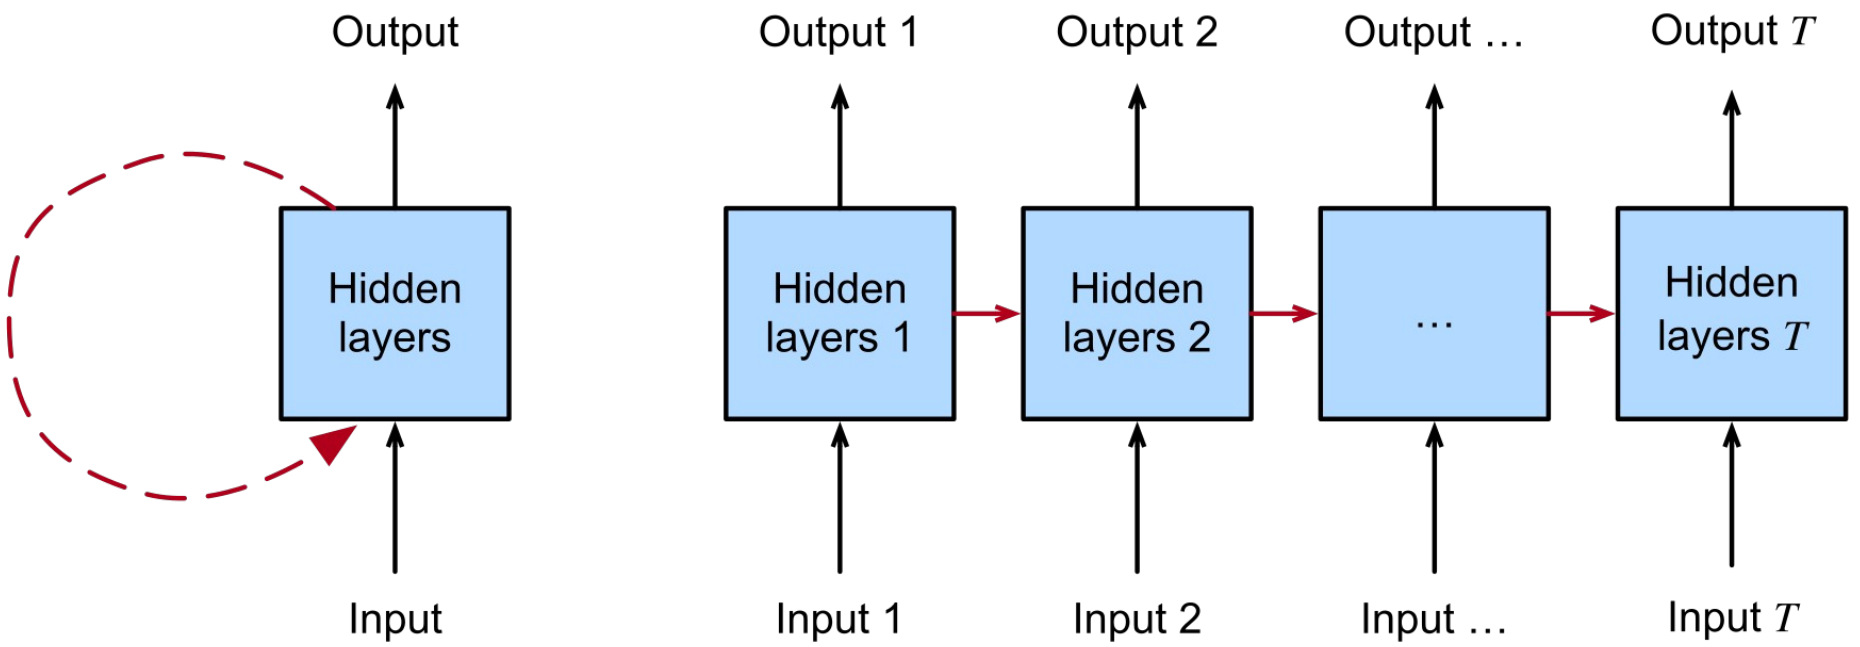
Входы и выходы RNN

x_t может быть числом, вектором признаков или представлением токена.

Задача	Вход	Выход
Один ответ на весь вход	Отзыв / ряд измерений	Класс / направление
Ответ на каждом шаге	Аудиокадры / токены	Речь или тишина / метки

Длину входа можно менять. Размер скрытого состояния задаём заранее.

Один блок, общие веса



Вход x_t **Состояние h_t** **Общие веса W**

Схема: Zhang et al., Dive into Deep Learning, CC BY-SA 4.0.

Что происходит на одном шаге

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b_h)$$

НОВЫЕ ДАННЫЕ

Что пришло сейчас

ПРЕДЫДУЩИЙ КОНТЕКСТ

Что осталось от прошлых шагов

Классификатор по последнему состоянию

$$p = \sigma(w^T h_t + b_y)$$

Между независимыми примерами $h_0 = 0$. В одном потоке состояние можно переносить дальше.

Три шага на конкретных числах

$$h_t = \tanh(0{,}5x_t + 0{,}8h_{t-1}), \quad h_0 = 0$$

Шаг	x_t	$0{,}5x_t + 0{,}8h_{t-1}$	h_t после tanh
1	1	0,5000	0,4621
2	0	0,3697	0,3537
3	-1	-0,2170	-0,2137

На втором шаге $x_2 = 0$, но $h_2 \neq 0$: влияет предыдущий вход.

Обратный порядок [−1, 0, 1] меняет итог: $h_3 \approx +0{,}2137$.

Обучение через время

01

Прямой проход

Входная последовательность
Предсказание и ошибка

02

BPTT

Градиенты от конца к ранним шагам

03

Обновление

Оптимизатор меняет общие веса

Один вес участвует много раз. Его градиент суммирует эти вклады.

BPTT: backpropagation through time. Усечённый вариант ограничивает длину обратного прохода.

Почему длинную историю трудно выучить

Затухание

$$0{,}8^{50}$$

≈ 0,000014

Обучающий сигнал
почти исчезает

Взрыв

$$1{,}2^{50}$$

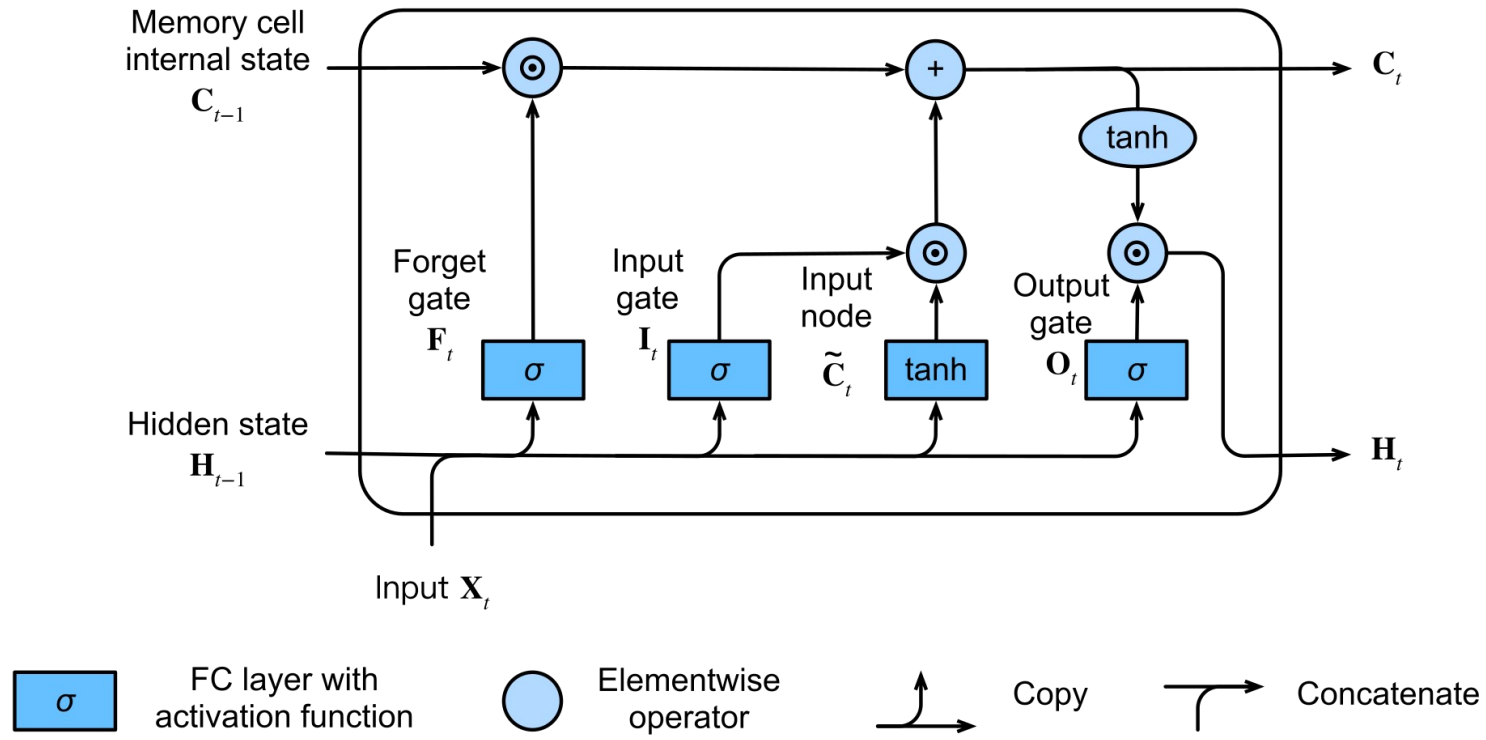
≈ 9 100

Обновление весов
может стать слишком большим

Иллюстрация: произведение 50 одинаковых множителей.

Clipping ограничивает взрыв. LSTM и GRU помогают сохранять обучающий сигнал на длинных цепочках.

LSTM управляет сохранением памяти



$\mathbf{f}_t$

Сохранить старое

$\mathbf{i}_t$

Записать новое

$\mathbf{o}_t$

Передать на выход

Вентили обучаются: значения от 0 до 1.

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t$$

Схема: Zhang et al., Dive into Deep Learning, CC BY-SA 4.0. ⊙ означает поэлементное умножение.

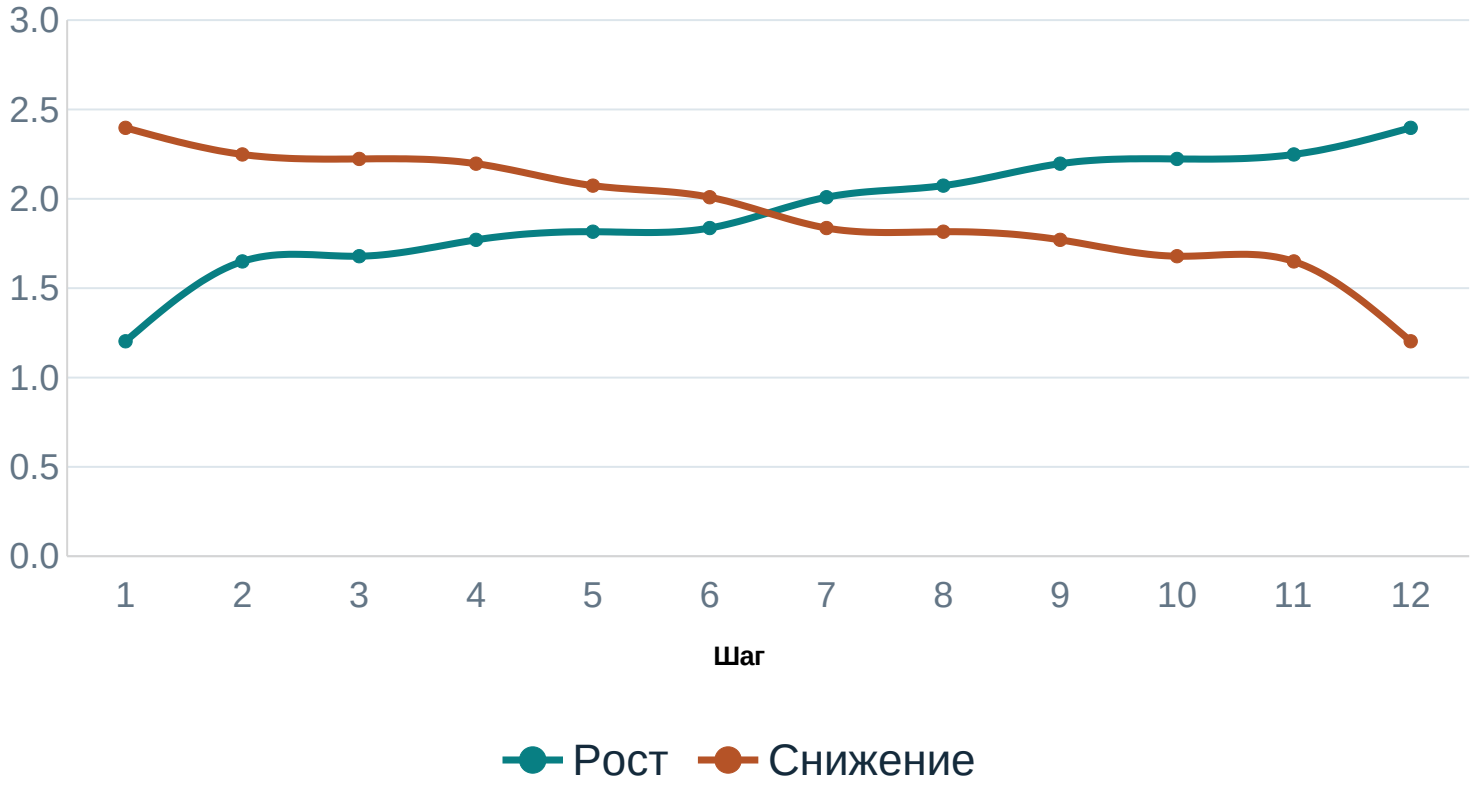
Обычная RNN, LSTM и GRU

Вариант	Состояние	Механизм
Обычная RNN	h	Один рекуррентный шаг
LSTM	h и c	Забывание, запись, выход
GRU	h	Обновление и сброс

При одинаковом размере состояния GRU обычно компактнее LSTM.

LSTM и GRU тоже относятся к рекуррентным сетям.

Эксперимент: распознать направление



512 / 256

примеров train / test

12 шагов

8 скрытых компонент

Пары разделены целиком: обратные копии остаются в одной выборке.

Весь прямой проход в одном цикле

```
h = np.zeros((batch, 8))
for t in range(12):
    h = np.tanh(
        X[:, t, :] @ Wx
        + h @ Wh + bh
    )
logits = h @ Wy + by
```

X

[batch, 12, 1]

h

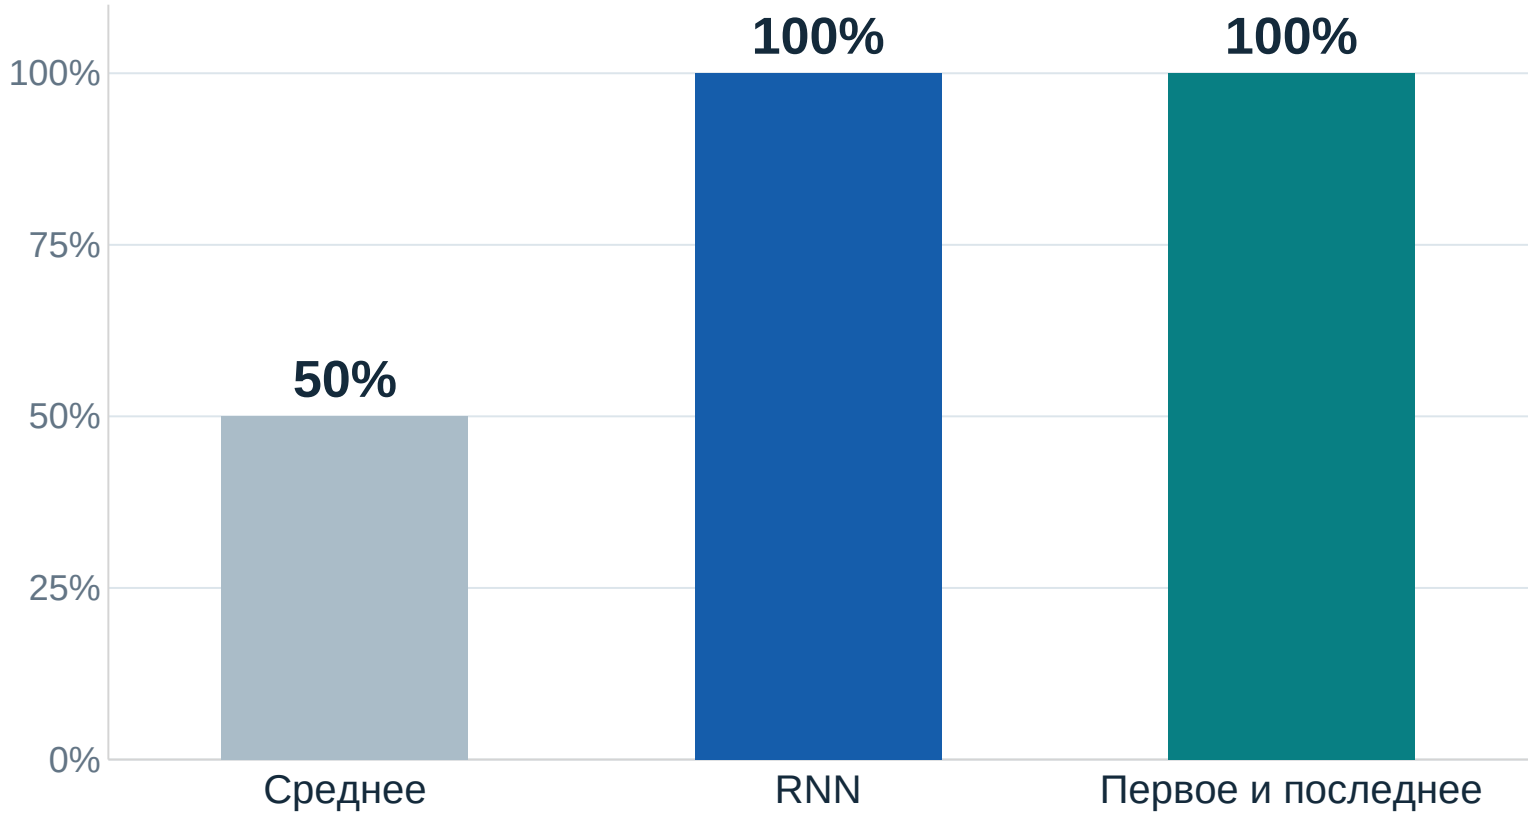
[batch, 8]

В NumPy @ означает умножение матриц

Sigmoid даёт вероятность класса. BPTT и Adam обучают параметры.

NumPy, 89 параметров, 150 эпох. Производные проверены конечными разностями.

RNN научилась решать учебную задачу



256

тестовых примеров

Простое правило тоже даёт 100%

Эта задача показывает механику RNN. Преимущество сети не доказано.

Где используется: обработка аудио

OBS Studio

RNNoise · GRU

Подавляет фоновые шумы в микрофонном сигнале

Рекуррентная модель учитывает соседние аудиокадры.

Silero VAD

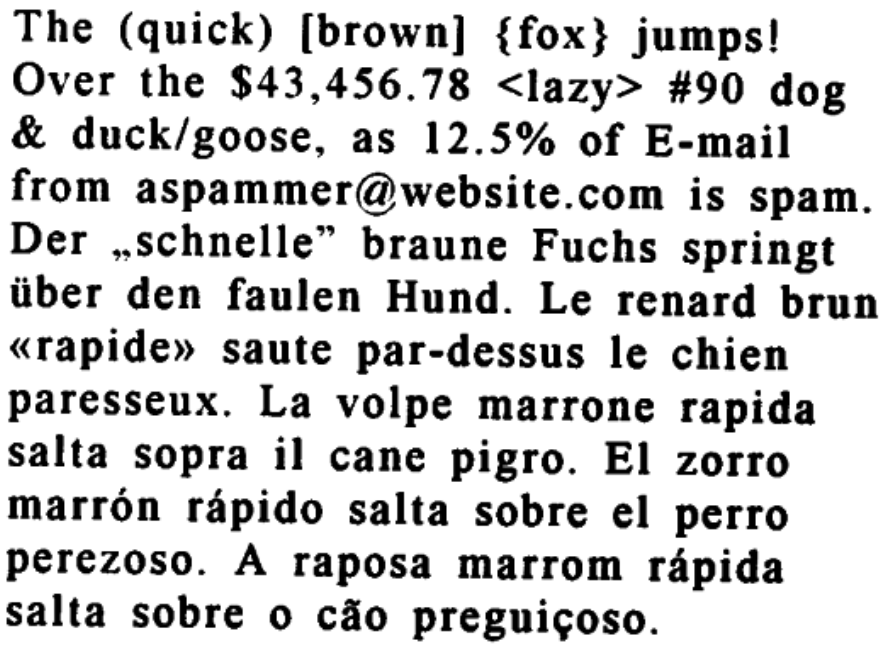
Интеграция в whisper.cpp

Находит участки речи перед распознаванием

LSTM переносит состояние между фрагментами звука.

Документация OBS, xiph/rnnoise, Silero VAD и whisper.cpp. Полные ссылки в заметках.

Где используется: распознавание текста



Tesseract 5

LSTM распознаёт строку изображения

Из последовательности визуальных признаков получаются символы. Результат можно искать и копировать.

```
--oem 1
```

Tesseract 5, Command Line Usage. Слева пример изображения из документации Tesseract.

Когда выбрать другой подход

Подход	Полезное свойство	Что учитывать
MLP по окну	Простая модель фиксированного входа	Размер окна задан заранее
1D CNN / TCN	Параллельный поиск шаблонов	Контекст задаёт архитектура
Transformer	Связи между далёкими позициями	Плотное attention: $O(T^2)$
RNN / LSTM / GRU	Компактное состояние потока	Последовательные вычисления

Выбор определяют качество, задержка и доступные вычисления.

Что важно запомнить

01

Порядок и состояние

Один блок повторяется с общими весами.

02

Обучение через время

BPTT вычисляет градиенты, оптимизатор меняет веса.

03

Применение по задаче

Потоки аудио, OCR и другие последовательности.

Размер состояния ограничен. Длинный вход не гарантирует длинную память.

Источники

Устройство и обучение

Dive into Deep Learning
RNN, BPTT, LSTM, GRU

Hochreiter & Schmidhuber, 1997
Long Short-Term Memory

Pascanu et al., 2013
On the difficulty of training RNNs

Современные применения

OBS: Noise Suppression Filter
Xiph RNNoise

Silero VAD v6.2.3
whisper.cpp: Voice Activity Detection

Tesseract 5
Command Line Usage

Ссылки на первоисточники есть в заметках и readme.md.

Дополнительные источники: Cho et al.; Vaswani et al.; Bai et al.